O papel de dados não rotulados em **Aprendizado de Máquina** 





Sem rótulo. E agora?



## Estratégias

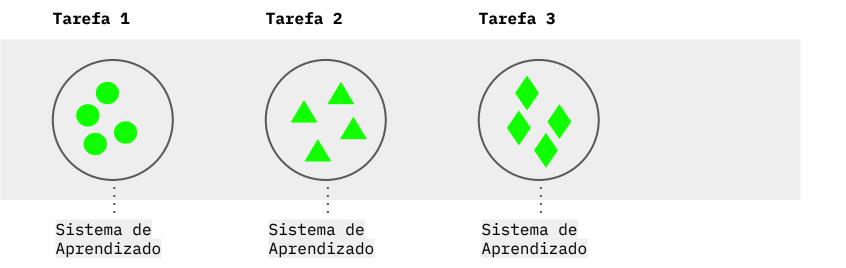
- não supervisionado,
  - o NLP
  - Autoencoder



Transfer Learning (NLP)



### Aprendizado de máquina tradicional





### Transfer Learning

# Dados Fonte Tarefa Objetivo (Target) Aprendizado Sistema de Aprendizado



# Transfer Learning (NLP)



- Tarefas da NLP compartilham conhecimento comum
- Dados anotados são raros
- Empiricamente, o aprendizado de transferência resultou em SOTA para muitas tarefas supervisionadas de NLP



### **Sequencial**



Aprender em uma tarefa/dataset, e depois transferir para outra tarefa/dataset







### Pré-Treino

- Quantidade alta de dados não rotulados disponível
- Wikipedia, notícias, web crawling, reddit, etc

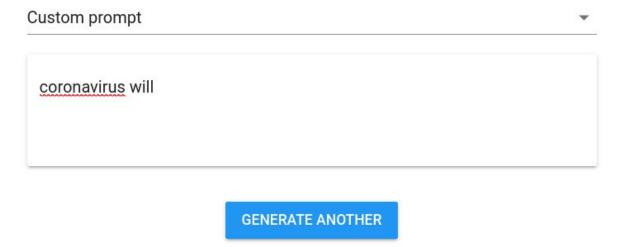


### Modelo de Linguagem Tradicional

- Distribuição de probabilidade sobre uma sequência de tokens
- Prever a próxima palavra
- Unidirecional
- Geração de linguagem



### GPT-2





### GPT-2

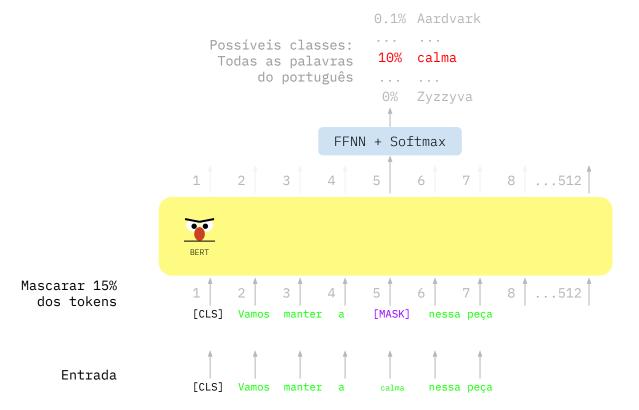
coronavirus will cause worsening gastroenteritis in some people, but its potential effect on health should not be devised in the absence of knowledge of the condition; contravention of transmission may require an impregnable condom



# Modelo de linguagem com máscaras

- Treinado para prever partes faltando ou tokens corrompidos.
- Bidirecional
- BERT





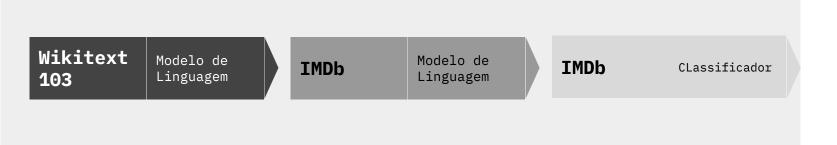


### Tarefas alvo

- Classificação de documentos
- Geração de texto
- Question answering



### Casos de uso: Classificação

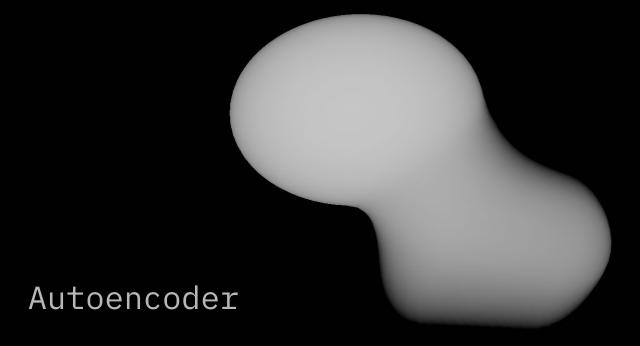




### Desafios Futuros

- Pré-treino é pesado
- Geração de fake news, spam, etc







### **Autoencoder**

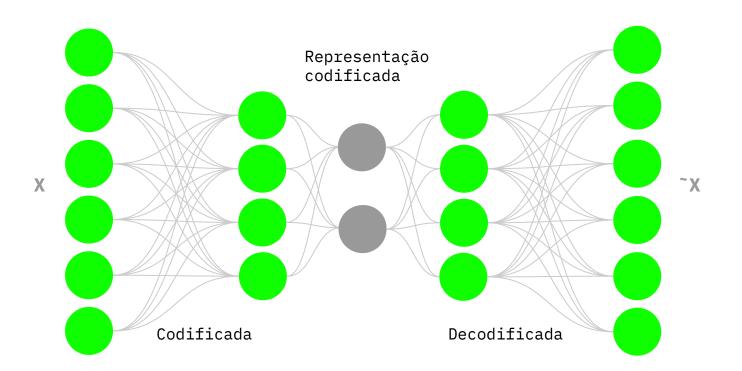




- Recolorir imagem
- Remover o ruído

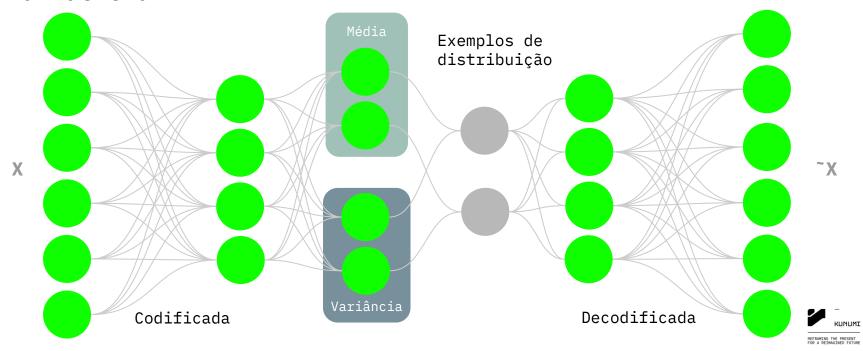


### Autoencoder

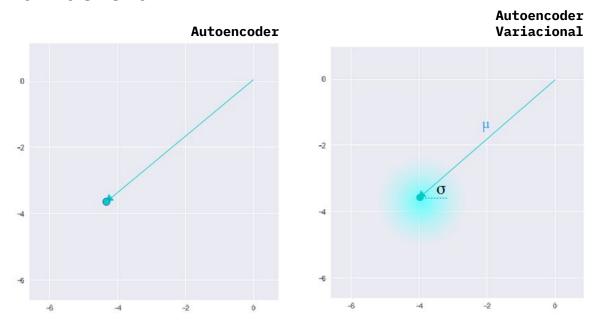




### Autoencoder Variacional



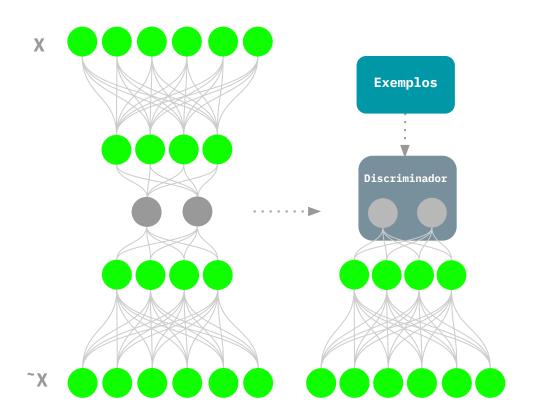
### Autoencoder Variacional







### Autoencoder Adversarial





### Autoencoder: uso

- Modelo
- Ponto de corte
- Validação



### Autoencoder: casos de uso

- Detecção de anomalias
- Saúde



### Thanks!

### **Perguntas?**

Fernanda Guimarães

www.linkedin.com/in/fernandaguim

Thays Silva

www.linkedin.com/in/thaysfsil



### Crédito

### Links:

```
https://medium.com/@mahmoudeljiddawi/auto-colorization-of-black-and-white-images-using-mach ine-learning-auto-encoders-technique-a213b47f7339
https://lilianweng.github.io/lil-log/2019/01/31/generalized-language-models.html
http://jalammar.github.io/illustrated-bert/
http://jalammar.github.io/illustrated-gpt2/
https://arxiv.org/pdf/1511.05644.pdf
https://towardsdatascience.com/anomaly-detection-with-autoencoder-b4cdce4866a6
https://towardsdatascience.com/intuitively-understanding-variational-autoencoders-1bfe67eb5daf
```

